

TABLA DE CONTENIDO

Índice de tablas	iii
Índice de ilustraciones	vi
1 INTRODUCCIÓN	1
2 MARCO TEÓRICO	3
2.1 Conjunto de datos utilizado	3
2.1.1 Conceptos asociados	3
2.1.2 Descripción del Conjunto de datos	3
2.2 Resultados obtenidos anteriormente	4
2.2.1 Problemas durante el entrenamiento de un red	5
2.3 Redes neuronales	7
2.3.1 Análisis del sistema	8
2.3.2 Preprocesamiento	8
2.3.3 Diseño de la red	12
2.3.4 Entrenamiento	13
2.3.4.1 Validación cruzada	13
2.3.5 Generalización	14
3 Resultados	15
3.1 Validación cruzada k=2	15
3.1.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia	16
3.1.1.1 Entrenamiento	16
3.1.1.2 Generalización	16
3.1.2 Entrenamiento con Normocapnia y Generalización con Hipercapnia	18
3.1.2.1 Entrenamiento	18
3.1.2.2 Generalización	18
3.2 Validación cruzada k=3	20
3.2.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia	20
3.2.1.1 Entrenamiento	20
3.2.1.2 Generalización	20
3.2.2 Entrenamiento con Normocapnia y Generalización con Hipercapnia	23
3.2.2.1 Entrenamiento	23
3.2.2.2 Generalización	23
3.3 Validación cruzada k=4	25
3.3.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia	25
3.3.1.1 Entrenamiento	26
3.3.1.2 Generalización	26
3.3.2 Entrenamiento con Normocapnia y Generalización con Hipercapnia	26
3.3.2.1 Entrenamiento	29
3.3.2.2 Generalización	29
4 ANÁLISIS	33
4.1 Validación Cruzada K = 2	36
4.1.1 Entrenamiento Hipercapnia	36
4.1.2 Entrenamiento Normocapnia	37
4.1.3 Hipercapnia	38
4.1.4 Normocapnia	39
4.2 Validación cruzada K = 4	39

4.2.1	Hipercapnia	39
4.2.2	Normocapnia	40
5	Conclusiones	43
	Bibliografía	45

ÍNDICE DE TABLAS

Tabla 3.1	Hiperparámetros utilizados	15
Tabla 3.2	Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.	16
Tabla 3.3	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	16
Tabla 3.4	Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.	18
Tabla 3.5	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	18
Tabla 3.6	Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.	20
Tabla 3.7	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	21
Tabla 3.8	Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.	23
Tabla 3.9	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	23
Tabla 3.10	Mser y Maer obtenidos durante las iteraciones con conjunto de entrenamiento.	26
Tabla 3.11	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	26
Tabla 3.12	Mser y Maer obtenidos durante las iteraciones con conjunto de entrenamiento.	29
Tabla 3.13	Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.	29

ÍNDICE DE ILUSTRACIONES

Figura 2.1	Ejemplificación del problema del sesgo.(Bajaj (2017))	6
Figura 2.2	Ejemplificación del problema de la varianza. (Bajaj (2017))	7
Figura 2.3	Señal original de ABP.	9
Figura 2.4	Señal de ABP normalizada.	10
Figura 2.5	Señal de ABP con tres retrasos, primeros instantes para apreciar gráficamente el retraso	10
Figura 2.6	Señal de ABP remuestreada. primeros instantes para apreciar gráficamente el remuestreo	11
Figura 2.7	Ejemplificación del funcionamiento de la validación cruzada para cuatro grupos.	13
Figura 2.8	Fórmula de mean squared error	14
Figura 2.9	Fórmula de mean absolute error	14
Figura 3.1	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A	17
Figura 3.2	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B	17
Figura 3.4	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B	19
Figura 3.3	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A	19
Figura 3.5	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A y B	21
Figura 3.6	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A y C	22
Figura 3.7	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B y C	22
Figura 3.8	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A y B	24
Figura 3.9	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A y C	24
Figura 3.10	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B y C	25
Figura 3.11	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, B y C	27
Figura 3.12	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, B y D	27
Figura 3.13	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, C y D	28
Figura 3.14	Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B, C y D	28
Figura 3.15	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, B y C	30
Figura 3.16	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, B y D	30
Figura 3.17	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, C y D	31
Figura 3.18	Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B, C y D	31

Figura 4.1	Conjuntos de entrada utilizados para el entrenamiento en hipercapnia (ABP).	33
Figura 4.2	Conjuntos de entrada utilizados para el entrenamiento en normocapnia (ABP).	34
Figura 4.3	Conjuntos de salida utilizados para el entrenamiento en hipercapnia (CBFV).	35
Figura 4.4	Conjuntos de salida utilizados para el entrenamiento en normocapnia (CBFV).	36

CAPÍTULO 1. INTRODUCCIÓN

Durante el desarrollo de la experiencia anterior se realizó una serie de experimentos en base a la implementación desde cero de una red neuronal multicapa para poder solucionar un problema de regresión consistente en la predicción del flujo sanguíneo cerebral según la presión arterial media.

En esta oportunidad, gracias a la implementación de una red neuronal de la biblioteca Sklearn, se busca mejorar los resultados obtenidos anteriormente a partir de la utilización de una red neuronal multicapa.

Para esto, se utiliza el mismo data set utilizado anteriormente correspondiente a las muestras tomadas por los Doctores Stephanie Deverson y Paul Hayes. En este se muestra la PAM y la CBFV antes, durante y después de la aplicación de la maniobra de manguitos.

Dicho esto es posible determinar cuáles son los objetivos a cumplir durante esta experiencia los cuáles corresponden a:

- Utilizar técnicas de pre-procesamiento adecuadas según el conjunto de datos escogido.
- Mejorar los resultados obtenidos en la experiencia anterior.
- Implementar validación cruzada con tres valores diferentes de pliegues.
- Realizar una optimización de los hiperparámetros de la red neuronal basada en *grid search*, *random parameter* u otra opción.

Para alcanzar estos objetivos, y como se adelantaba anteriormente, las herramientas utilizadas corresponde a *Python* en su versión 2.7 y las librerías:

- Numpy: esta es una biblioteca matemática básica que permite realizar operaciones matemáticas más complejas con una notación sencilla, por ejemplo, manejo de matrices.
- Scipy: esta es una biblioteca matemática que contiene una serie de funciones matemáticas avanzadas para la aplicación de Python a problemas científicos. En esta experiencia es utilizada para el manejo de señales.

- Sklearn: Esta es la biblioteca esencial para esta experiencia, ya que contiene las implementaciones de diferentes métodos de aprendizaje máquina. Siendo utilizado en esta experiencia la red neuronal multicapa.
- Pandas: Es una biblioteca que entre sus funciones se encuentra el manejo sencillo de conjuntos de datos.
- Matplotlib: Es una biblioteca que permite la generación de gráficos de un modo sencillo y elegante. Durante la experiencia es utilizada para observar las señales originales y las generadas por la red neuronal creada, además de los errores y otras características interesantes de los experimentos.

La estructura del reporte presentado corresponde a:

- Introducción: se plantean los temas a tratar
- Marco Teórico: Donde se explican los conceptos biológicos necesarios para estudiar el conjunto de datos y asu vez se describe el conjunto de datos. Mientras que también se explican las técnicas que son utilizadas para obtener información desde los datos, las cuáles corresponden a la validación cruzada, feature extraction, etc.
- Resultados: En esta parte del informe se muestran los resultados del entrenamiento de las redes, tanto la comparación de las señales obtenidas como del error en cada una de ellas.
- Análisis: en esta etapa se busca determinar las implicancias de los resultados en cuánto al funcionamiento de las redes neuronales.
- Conclusiones: se hace el panorama de toda la experiencia, se concluye cuáles procedimientos fueron acertados y cuáles son susceptibles a mejoras y cómo estos resultados pueden ser estudiados posteriormente.

CAPÍTULO 2. MARCO TEÓRICO

2.1 CONJUNTO DE DATOS UTILIZADO

2.1.1 Conceptos asociados

Para la correcta realización de esta experiencia es necesario definir una serie de conceptos biológicos relacionados a la auto-regulación cerebral que permiten interpretar correctamente los resultados obtenidos.

Brevemente explicados los principales conceptos necesarios para la definición de esta experiencia corresponden a:

- Presión arterial Media (Por sus siglas en inglés ABP): corresponde a la presión de la sangre en las arterias, medida en milímetro de mercurio (mmHG).
- Velocidad de flujo sanguíneo cerebral (Por sus siglas en inglés CBFV): Corresponde a la velocidad en que se mueve un frente vectorial en una arteria del cuerpo, en este caso particular es medida en centímetros por segundo en la arterial cerebral media.
- Maniobras de los manguitos: es una maniobra utilizada para provocar una baja repentina en la presión arterial media. Consiste en la inflación durante 3 minutos aproximada de dos manguitos, uno en cada muslo, con una presión aproximada de 15 mmHg sobre la presión arterial media, para luego desinflarlos repentinamente provocando una baja de presión repentina.

2.1.2 Descripción del Conjunto de datos

El conjunto de datos utilizados corresponde a una recolección de datos obtenidos de dieciséis pacientes todos sujetos sanos por los Doctores Stephanie Deverson y Paul Hayes. Con estos datos se realiza el estudio de la autorregulación cerebral en búsqueda de evaluar la

utilización del ARI como una medida fiable para medir este fenómeno. Los datos de los pacientes son recolectados en base a las siguientes características en sujetos normales antes, durante y después de la utilización de una maniobra para la caída de presión arterial media, siendo en este caso la técnica de los manguitos.

Las señales relevantes para el estudio de esta experiencia corresponden a la velocidad de flujo sanguíneo cerebral (CBFV) y a la presión arterial media (ABP). Estas señales duran al rededor de 5 minutos y son muestreadas en intervalos de tiempo de 0.2 s.

Dicho, lo anterior se plantea realizar un modelo que sea capaz de predecir una señal CBFV en base a la PAM. Durante la experiencia se estudian las señal provenientes del mismo sujeto en condiciones de normocapnia e hipercapnia y se busca determinar si es posible poder determinar si es posible generalizar un modelo que fue entrenado en la situación contraria. Dicho de un modo más claro, si es posible, por ejemplo, entrenar un modelo en normocapnia y determinar si este modelo es capaz de determinar la CBFV en situación de hipercapnia y viceversa.

2.2 RESULTADOS OBTENIDOS ANTERIORMENTE

Durante la experiencia anterior se llegaron a resultados muy pobres de la implementación de la red neuronal multicapa. Siendo estos visualizados en el pobre aprendizaje que realizó la red en cuanto a la predicción de la CBFV, esta situación puede ser explicada por los siguientes motivos:

- Falta de aprendizaje: el primer error cometido en la experiencia anterior correspondió a utilizar la señal completa para el entrenamiento y no punto a punto, como es explicado en el siguiente punto. Provocando que el entrenamiento y la retropropagación se realizará incorrectamente.
- Muestreo de las señales: este error corresponde a que el entrenamiento de la señal no fue realizado punto a punto, con sus retrasos correspondientes, si no que fue tomada en su

totalidad para el entrenamiento. Lo que lleva a un diseño de la red errado inmediatamente, ya que las neuronas de entrada crecen notablemente, según la cantidad de muestras y las neuronas de la capa oculta disminuyen en base a considerar una señal una única muestra. Provocando un fenómeno de sesgo como se ejemplifica en la figura 2.1

- Validación cruzada: en la experiencia anterior al utilizar una señal completa para el entrenamiento no hubo ninguna perspectiva de la calidad del modelo con respecto a un conjunto de prueba. Llevando a la falta de visualización de los errores en vista de encontrar soluciones viables para los problemas observados en la red.
- Falta de normalización: Consecuencia de la utilización de datos no normalizados, es posible que el espacio de búsqueda de mínimos, tenga curvas de nivel parecidas a una banana y por tanto, la búsqueda de un mínimo en base al método de la gradiente descendiente se vuelve muy lento, lo que también explicaría, porque el proceso de aprendizaje es tan lento.

Por lo tanto, los aspectos a mejorar en esta experiencias se pueden resumir en el correcto diseño de la red neuronal basándose en la nueva perspectiva de conocimientos obtenidos correspondientes al diseño del red, cantidad de neuronas de entrada, en la capa oculta y de salida y funciones de activación y transferencia, también se tiene conocimiento de que no hay que hacer para entrenar una red para evitar el problema del sesgo y finalmente se puede mostrar

2.2.1 Problemas durante el entrenamiento de un red

Consecuencia de la experiencia anterior y de lo crítico que se puede volver lidiar correctamente con el sesgo y la varianza es que se considera pertinente explicar a qué se refieren estas ideas:

- Problema del sesgo: Este problema durante es consecuencia de que la red no está siendo entrenada apropiadamente y por tanto, los resultados obtenidos tienen un ajuste muy pobre con respecto a los resultados esperados, tal como se observa en la figura 2.1. Existen dos maneras principales para evitar este problema, que corresponden a:




Figura 2.1: Ejemplificación del problema del sesgo.(Bajaj (2017))

- Repetir entrenamiento: Una de las complejidades del espacio de búsqueda de la función de costos corresponde a la existencia de mínimos locales en dónde el gradiente descendiente, utilizado para la retropropagación, puede quedar atrapado, sin poder llegar a un mejor mínimo, provocando un pobre entrenamiento final de la red. Luego, consecuencia de que este resultado está estrechamente relacionado con los pesos iniciales de la red se aconseja realizar varios entrenamientos, por lo menos diez, para llegar un resultado más apropiado.
- Parámetros de la red: Otra de las causas del sesgo corresponde a la utilización de muy pocos parámetros en la capa oculta de la red simplificando las salidas de las activaciones y finalmente alejándose de la función que sea desea aproximar. Una forma de mejorar este punto corresponde al aumento cauteloso de la cantidad de neuronas en la capa oculta.
- Problema de la varianza: Este problema es la contraparte de la problema de sesgo, como se observa en la figura 2.2 en este existe una memorización de los datos más que un aprendizaje y por tanto, existe una pobre generalización del modelo. Este problema puede estar causado por dos motivos:
 - Sobreparametrización: Esta causa corresponde a la utilización de un número excesivo




Figura 2.2: Ejemplificación del problema de la varianza. (Bajaj (2017))

de neuronas en la capa oculta. Por tanto se recomienda graficar el error del conjunto de test y de entrenamiento según la cantidad de parámetros, para detener el entrenamiento en el punto en que el error del conjunto de test aumenta su error.

- Sobreaprendizaje: esta causa corresponde a un número de iteraciones en el aprendizaje muy grande, provocando la memorización de los datos. La recomendación es análoga a la anterior, pero se debe estudiar el error en contra de la cantidad de iteraciones.

De modo implícito queda la utilización de validación cruzada, la cual es explicada a continuación. Pero también se recomienda utilizar la regularización, la cuál consiste en aplicar un factor penalización en la función de costos dependiendo de la complejidad del modelo.

2.3 REDES NEURONALES

Dentro las etapas para la utilización de una red neuronal se encuentran al menos cinco, las que corresponden al análisis del sistema, al preprocesamiento de los datos, al diseño de la red, al entrenamiento y a la generalización.

2.3.1 Análisis del sistema

Como se ha mencionado anteriormente el modelo que es creado durante esta experiencia corresponde a un regresor de la CBFV en base a la ABP, como se plantea en 2.1.2. Uno de los supuestos fuertes para esta experiencia corresponde a la no linealidad del fenómeno de la auto-regulación cerebral, el cuál es el que permite utilizar una red neuronal multicapa en la predicción de los datos de CBFV en base a la ABP. De lo contrario, según la cátedra no sería recomendable utilizar este tipo de modelado. Finalmente, se sabe que para el entrenamiento de un modelo de autoregulación cerebral se requieren al menos 5 minutos, siendo la señal lo suficientemente larga como para entrenar la red.

2.3.2 Preprocesamiento

Para el procesamiento de señales se realizan dos procesos básicos correspondientes a:

- Normalización: Para el correcto aprendizaje de la red, entregando una superficie de búsqueda sin deformaciones consecuencia de la influencia de las diferencias de escalas de las dimensiones. Se aplica una normalización a los datos a partir de la fórmula 2.1, dejando los ejemplos en el intervalo de 0 y 1.

$$X_n = \frac{X_n - X_{min}}{X_{max} - X_{min}} \quad (2.1)$$

- Aplicación de retrasos: Se aplican retrasos a la señal con el objetivo de mejorar la predicción dando información de la señal en momentos pasados. Para esta experiencia son realizados tres retrasos y por tanto la señal de entrada de la ABP termina siendo una entrada con tres características correspondientes a la señal en el tiempo n , $n-1$ y $n-2$.
- Remuestreo de la señal: este preprocesamiento corresponde al remuestreo de cada señal cada 0.6 segundos. Esta recomendación es realizada con el objetivo de minimizar la




Figura 2.3: Señal original de ABP.

influencia del ruido inherente del muestreo de la señal.

En las figuras 2.4, 2.5 y 2.6, se toma como ejemplo la señal de ABP y se observa cómo la señal es modificada según cada una de las aplicaciones de preprocesamiento descritos anteriormente.

Otras técnicas utilizadas para el preprocesamiento corresponden a:

- Feature extraction: Esta técnica corresponde a la generación de características que están implícitas dentro de un conjunto de datos y que por tanto, puede entregar más información, con le objetivo de evitar redundancias. Facilitando los pasos de entrenamiento, generalización y finalmente la interpretación humana. En una señal es posible obtener una serie de características que pueden entregar información extra sobre el fenómeno que están capturando las cuáles pueden corresponder a:
 - Transformada de Fourier: permite realizar una transformación desde el mundo del tiempo hasta el mundo de las frecuencias, entregando información sobre el espectro de frecuencias que tiene la señal De Nápoli (2017). Matemáticamente hablando queda




Figura 2.4: Señal de ABP normalizada.




Figura 2.5: Señal de ABP con tres retrasos, primeros instantes para apreciar gráficamente el retraso




Figura 2.6: Señal de ABP remuestreada. primeros instantes para apreciar gráficamente el remuestreo

expresado como:

$$\hat{f}(\omega) = \int_{-\infty}^{\infty} f(x)e^{-ix\omega} dx \quad (2.2)$$

Sin embargo, hay que tener en consideración que la definición formal puede cambiar según el texto utilizado, debido al agregado de ciertos factores que permite simplificar el cálculo de una transformada.

- Transformada Wavelet: Según Samir Kouro (2017) Corresponde al paso siguiente de la transformada de Fourier, en esta se realiza una transformación a partir de una ventana variable en la cual se usan ventanas largas para las regiones con baja frecuencia y ventanas pequeñas para las regiones con alta frecuencia. Básicamente, se realiza la multiplicación de la señal original por una ventana de tamaño S con la señal de Wavelet. Luego se realiza el corrimiento de la ventana y se repite el proceso hasta barrer toda la señal. Finalmente, el proceso debe ser repetido para todos los valores hasta tener

la transformada de Wavelete. Sin embargo, si se necesita calcular en un computador basta con utilizar un valor de S muy pequeño.

- *Feature Selection*: A diferencia de *features extraction*, en la cual se deben obtener características no visibles en un principio, en este proceso se busca determinar cuáles son los datos son los más relevantes. Con el objetivo de poder realizar un modelo más sencillo y por tanto, sea más simple de entrenar.

2.3.3 Diseño de la red

Para el diseño de la red se toma en consideración la cantidad de parámetros, es decir, la cantidad de pesos intersinápticos y la cantidad de neuronas en la capa oculta. Ya que el código empaquetado de *Sklearn*, contiene parámetros asociados a estas características, se pueden realizar variaciones en base a las ecuaciones entregadas en la cátedra de Ingeniería neuronal las cuales corresponden a:

$$N_w \leq \frac{n^{\circ} \text{demuestras}}{10} \quad (2.3)$$

$$N_w = (N_e + 1)N_c + (N_c + 1)N_s \quad (2.4)$$

Donde los parámetros corresponden a:

- N_w : Cantidad de pesos en la red neuronal.
- N_c : Cantidad de neuronas en la capa oculta.
- N_s : Cantidad de Salidas.
- N_e : Cantidad de entradas.

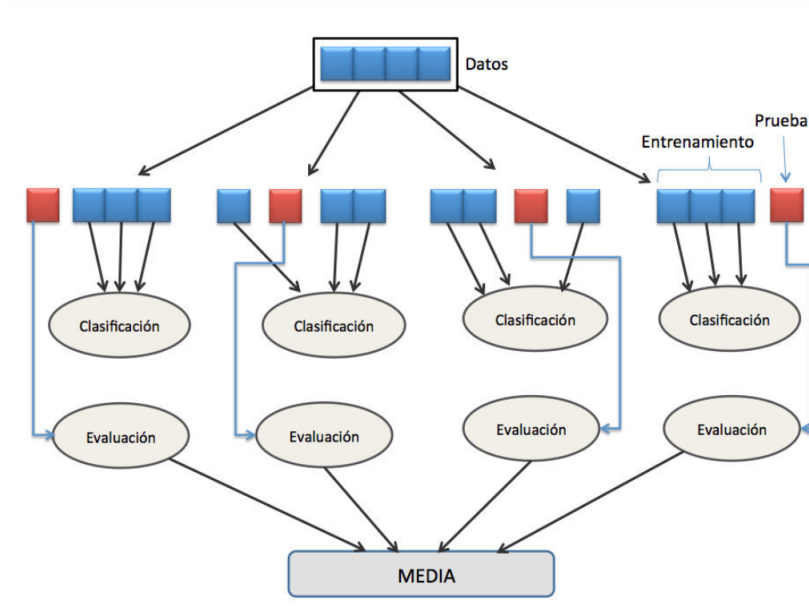


Figura 2.7: Ejemplificación del funcionamiento de la validación cruzada para cuatro grupos.

2.3.4 Entrenamiento

Para el entrenamiento de la red y la elección del mejor modelo, se utiliza la técnica de validación cruzada, con el objetivo de evitar los problemas mencionados en 2.2.1

2.3.4.1 Validación cruzada

La validación cruzada corresponde a una técnica de evaluación de resultados de modelos principalmente predictivos. Produciendo particiones en los datos consiguiendo grupos conocidos como conjunto de entrenamiento y conjunto de prueba.

Durante la experiencia esta técnica es aplicada con particiones de dos, tres y cuatro grupos, con el objetivo de determinar cuál es el mejor particionamiento de la señal para el entrenamiento, cómo afecta a los resultados la utilización de particiones a un fenómeno temporal+. El procedimiento queda expresado en la figura 2.7.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2$$

Figura 2.8: Fórmula de mean squared error

$$\text{MAE} = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

Figura 2.9: Fórmula de mean absolute error

2.3.5 Generalización

Finalmente, para la generalización se utiliza un conjunto de datos que nunca ha sido visto por el modelo, con el objetivo de determinar si es capaz de predecir correctamente datos desconocidos. A partir de su desempeño es posible calcular una serie de métricas que permiten medir la calidad del modelo utilizado. En la presenta experiencia es utilizada el MSER y el MAER, que corresponden a:

- MSER (Mean squared error): corresponde al promedio de las diferencias al cuadrado de la salida esperada y la salida estimada. Matemáticamente hablando queda expresado en la figura 2.8
- MAER (Mean absolute error): Corresponde al promedio del valor absoluto de las diferencias de la salida esperada y la salida estimada. Matemáticamente hablando queda expresado en la figura ecuación 2.9

Durante el desarrollo de la experiencia se utiliza una generalización utilizando el conjunto del mismo paciente, pero en el estado de concentración de Co2 contrario con el que se entrenó el modelo. Por ejemplo, si se entrenó el modelo con la señal en hipercapnia se generaliza con los datos en normocapnia, en búsqueda de encontrar diferencias en cuánto a la calidad de la predicción realizada.

CAPÍTULO 3. RESULTADOS

A continuación se realiza la revisión de resultados obtenidos durante el entrenamiento, cada resultado está agrupado dentro de la cantidad de pliegues utilizados para la validación cruzada es decir $k=2$, $k=3$ y $k=4$. Los parámetros utilizados en todas estas pruebas corresponden a:

- Activación: ReLU
- Cantidad de neuronas: Función en base a las fórmulas presentadas en 2.4
- Alpha : 0.01

Estos son obtenidos a partir del proceso de optimización de parámetros con Grid Search. Donde se probó con los hiperparámetros de la tabla 3.1

3.1 VALIDACIÓN CRUZADA K=2

En esta sección se utiliza una validación cruzada de dos grupos, por tanto primero se entrena con una mitad de la señal y se prueba con la restante y viceversa. La nomenclatura utilizada divide la señal en una sección A y una sección B.

Los errores obtenidos durante la etapa de entrenamiento corresponden a los observados en la tabla 3.2:

Tabla 3.1: Hiperparámetros utilizados

Tasa de aprendizaje	Función de activación	Cantidad de Neuronas capa oculta
0.001	Identidad	2
0.003	Logística	3
0.01	Tangente hiperbólica	4
0.03	Relu	5
0.1	-	6
0.3	-	Obtenidas de ecuación 2.4

3.1.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia

En esta sección se utiliza la señal de un sujeto en estado de hipercapnia para determinar el modelo predictivo de la señal de CBFV. Como se menciona la señal es dividida en una sección A y B.

3.1.1.1 Entrenamiento

Como se observa en la tabla 3.2 en este caso la mejor aproximación a la señal obtenido corresponde a la del modelo generado con la sección A, sin embargo no es mucho mejor que el modelo B, situación que puede ser estudiada a fondo durante el análisis.

Tabla 3.2: Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A	B	0.055427	0.211156
B	A	0.077555	0.227133

3.1.1.2 Generalización

La generalización es realizada utilizando las señales del mismo sujeto, pero en esta ocasión en condiciones de Normocapnia y como se observa la generalización utilizada con el modelo generado por A sigue siendo la mejor, situación que es expresada en los errores mostrados en la tabla 3.3 y que muestra una diferencia significativa a diferencia de lo ocurrido durante el entrenamiento. Por otro lado, las predicciones son mostradas en las figuras 3.1 y 3.2.

Tabla 3.3: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.

Conjunto de entrenamiento	Mser	Maer
A	0.047343	0.183398
B	0.189207	0.386172

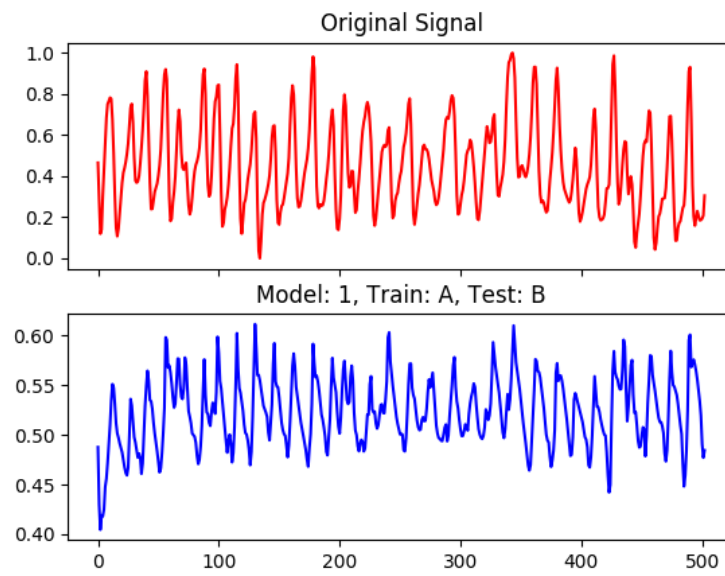


Figura 3.1: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A




Figura 3.2: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B

3.1.2 Entrenamiento con Normocapnia y Generalización con Hiperapnia

A continuación se hace el mismo procedimiento mencionado anteriormente, pero se utilizan las señales del sujeto en normocapnia para el entrenamiento de la red.

3.1.2.1 Entrenamiento

Los resultados muestran que el mejor modelo es obtenido con la el entrenamiento de B, como se observa en la tabla 3.4.

Tabla 3.4: Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A	B	0.061698	0.208620
B	A	0.050401	0.187064

3.1.2.2 Generalización

Como se mencionaba anteriormente para la generalización se utilizan los datos del sujeto en situación de hiperapnia, siendo los resultados de los errores obtenido expresados en la tabla 3.5 y las predicciones mostradas en las figuras 3.3 y 3.4.

Tabla 3.5: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.

Conjunto de entrenamiento	Mser	Maer
A	0.055302	0.191487
B	0.108861	0.298377

Las señal obtenidas con cada uno de los modelos corresponden a:

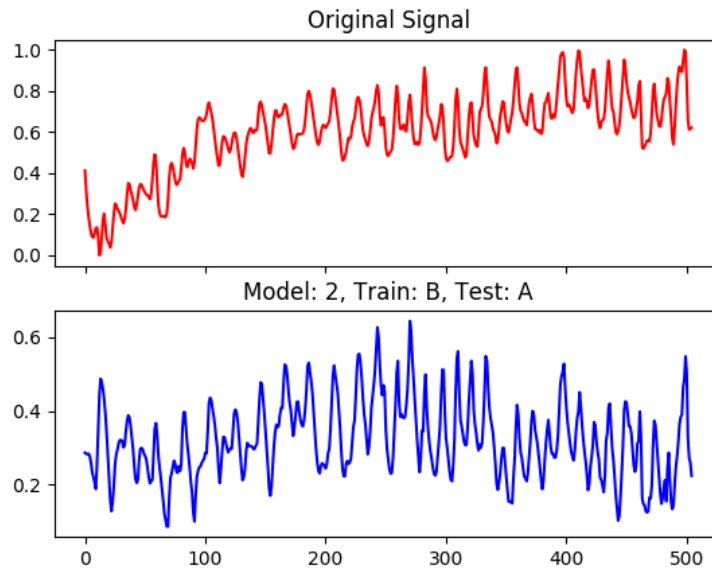


Figura 3.4: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B

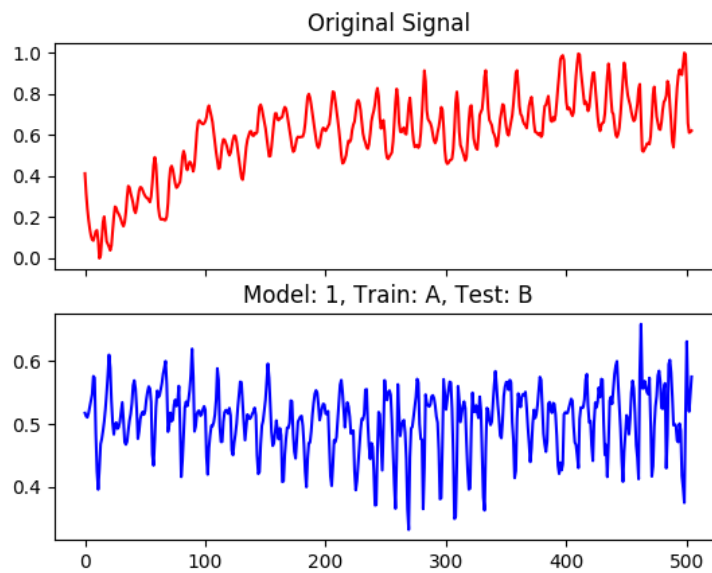


Figura 3.3: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A

3.2 VALIDACIÓN CRUZADA K=3

En este caso se utilizan las señales del sujeto divididas en tres secciones. Las cuales son nombradas como A, B y C. El entrenamiento y la prueba es realizado con la combinatoria de estas señales, considerando siempre el orden temporal, es decir, si A ocurre antes que C, el modelo se entrena concatenando A y luego C, mas no viceversa.

3.2.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia

Se utilizan los datos del sujeto en hipercapnia para el entrenamiento de la red y de normocapnia para la generalización.

3.2.1.1 Entrenamiento

Como se observa en la tabla 3.6, el mejor modelo corresponde al que está entrenado con las señales A y C.

Tabla 3.6: Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A y B	C	0.047429	0.192345
A y C	B	0.033044	0.138371
B y C	A	0.120052	0.286762

3.2.1.2 Generalización

Para la generalización se utilizan los datos generados a partir del sujeto en situación de normocapnia, siendo los errores expresados en la tabla 3.7 y las predicciones realizadas en las figuras 3.5, 3.6 y 3.7.

Tabla 3.7: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.

Conjunto de entrenamiento	Mser	Maer
A y B	0.078331	0.235722
A y C	0.063135	0.216431
B y C	0.105065	0.277183




Figura 3.5: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A y B




Figura 3.6: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A y C

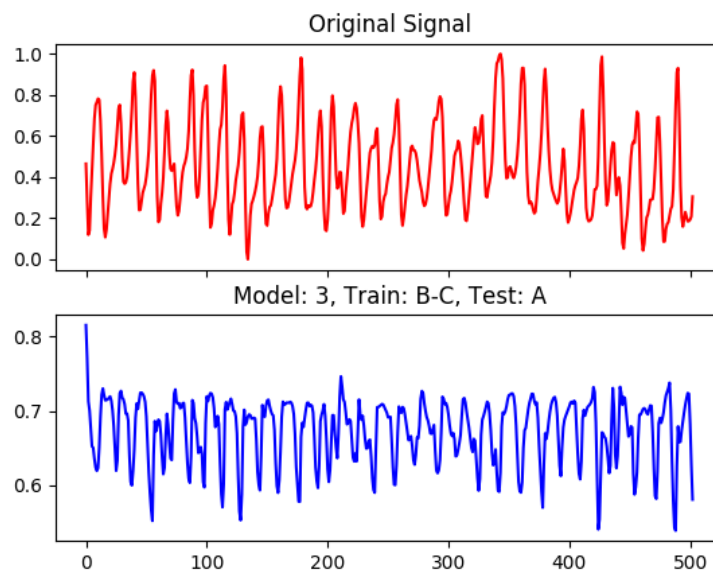


Figura 3.7: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B y C

3.2.2 Entrenamiento con Normocapnia y Generalización con Hiperapnia

En esta sección se utilizan los datos normocapnia para la realización del entrenamiento e hiperapnia para la generalización.

3.2.2.1 Entrenamiento

El error durante el entrenamiento es expresado en la tabla 3.8 y muestra que el mejor modelo es nuevamente obtenido entrenando entre las secciones A y C.

Tabla 3.8: Mser y Maer obtenidos durante las iteraciones con conjunto de prueba.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A y B	C	0.091626	0.256286
A y C	B	0.029223	0.141751
B y C	A	0.065149	0.212342

3.2.2.2 Generalización

Durante la generalización y como se muestra en la tabla 3.9, el mejor modelo se mantiene y las predicciones están expresadas en las figuras 3.8, 3.9 y 3.10.

Tabla 3.9: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización.

Conjunto de entrenamiento	Mser	Maer
A y B	0.060173	0.193264
A y C	0.057593	0.212342
B y C	0.171611	0.372232




Figura 3.8: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A y B




Figura 3.9: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A y C

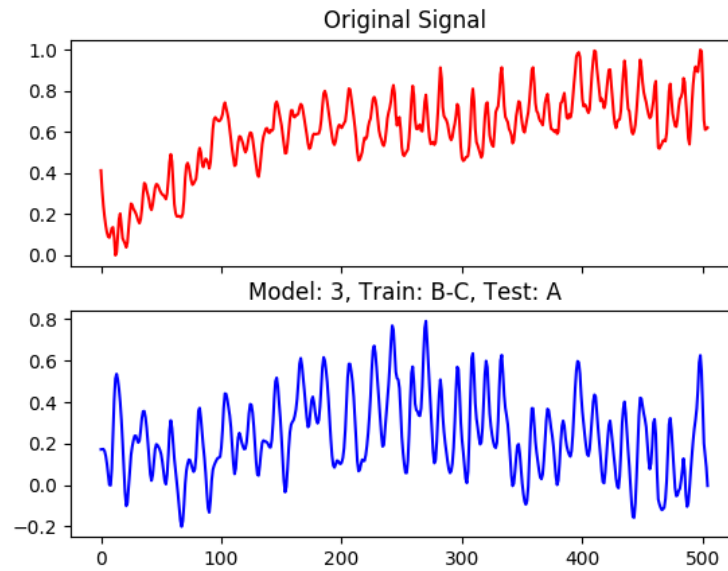


Figura 3.10: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B y C

3.3 VALIDACIÓN CRUZADA K=4

Durante la validación cruzada para cuatro grupos se dividen las señales en A,B,C y D. Siguiendo las mismas reglas propuestas para la validación cruzada con $k = 3$, es decir, no existe una inversión en el orden de la señal, por lo tanto no se concatena, por ejemplo, la señal de A, C y B si no que siempre es A,B y C.

3.3.1 Entrenamiento con Hipercapnia y Generalización con Normocapnia

En esta sección los modelos obtenidos se entrenan con los datos en Hipercapnia y son generalizados con los datos en normocapnia.

3.3.1.1 Entrenamiento

Durante el entrenamiento se observa que los mejores resultados son obtenidos con el modelo generado a partir de las secciones A,C y D, lo que queda expresado en la tabla 3.10

Tabla 3.10: Mser y Maer obtenidos durante las iteraciones con conjunto de entrenamiento.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A, B y C	D	0.062276	0.236621
A,B y D	C	0.075668	0.225527
A,C y D	B	0.022873	0.120405
B,C y D	A	0.112158	0.286089

3.3.1.2 Generalización

Para la generalización los errores quedan expresados en la tabla 3.11 y muestra que el mejor modelo generalizando corresponde a A, B y C. A demás, las predicciones son mostradas en las figuras 3.11, 3.12, 3.13 y 3.14.

Tabla 3.11: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización

Conjunto de entrenamiento	Mser	Maer
A, B y C	0.075767	0.230787
A,B y D	0.241838	0.414457
A,C y D	0.100302	0.273030
B,C y D	0.128944	0.308608

3.3.2 Entrenamiento con Normocapnia y Generalización con Hiperapnia

Como ya es habitual, se utilizan las señales del sujeto en situación de normocapnia para el entrenamiento de la red y las señales en hiperapnia para la generalización del modelo.




Figura 3.11: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, B y C




Figura 3.12: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, B y D




Figura 3.13: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP A, C y D




Figura 3.14: Predicción de la señal de CBFV en normocapnia con modelo entrenado con señal ABP B, C y D

3.3.2.1 Entrenamiento

Con la observación de la tabla 3.12, se observa que el mejor modelo es obtenido con el entrenamiento con las señales A, C y D, pero no es un modelo definitivamente mejor a los demás considerando las pequeñas variaciones.

Tabla 3.12: Mser y Maer obtenidos durante las iteraciones con conjunto de entrenamiento.

Conjunto de entrenamiento	Conjunto de prueba	Mser	Maer
A, B y C	D	0.055362	0.199003
A, B y D	C	0.038977	0.154738
A, C y D	B	0.032627	0.148690
B, C y D	A	0.035999	0.161168

3.3.2.2 Generalización

Para la generalización se utilizan los datos del sujeto en situación de hipercapnia. Observando que en esta ocasión los mejores resultados son obtenidos con el modelo entrenado por A,B y D. Las predicciones durante la generalización son mostradas en las figuras 3.15, 3.16, 3.17 y 3.18.

Tabla 3.13: Mser y Maer obtenidos durante las iteraciones con conjunto de generalización

Conjunto de entrenamiento	Mser	Maer
A, B y C	0.065152	0.226467
A,B y D	0.064826	0.227305
A,C y D	0.076760	0.248303
B,C y D	0.096924	0.275077




Figura 3.15: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, B y C

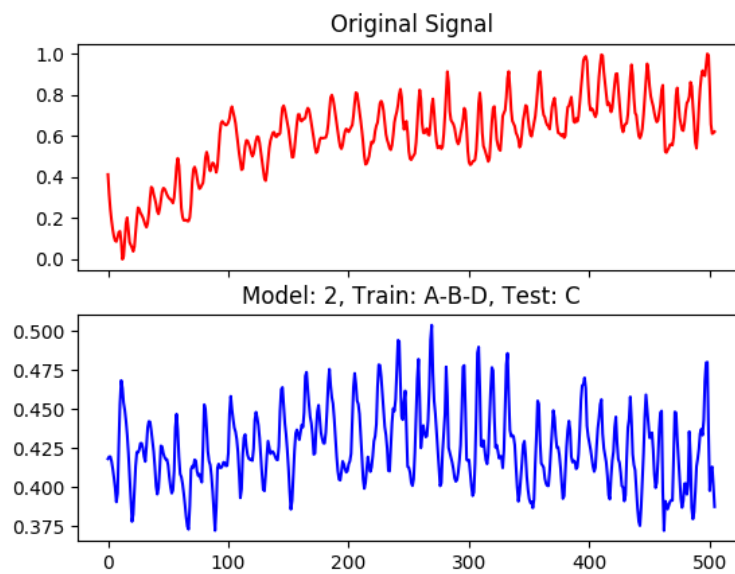


Figura 3.16: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, B y D




Figura 3.17: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP A, C y D




Figura 3.18: Predicción de la señal de CBFV en hipercapnia con modelo entrenado con señal ABP B, C y D

CAPÍTULO 4. ANÁLISIS

Para realizar los análisis y que estos tengan ideas significativas es necesario determinar cuáles son las porciones de las señales que son utilizadas para el entrenamiento de la red, a continuación son mostradas las ABP. Estas quedan expresadas en las figuras 4.1 y en 4.2

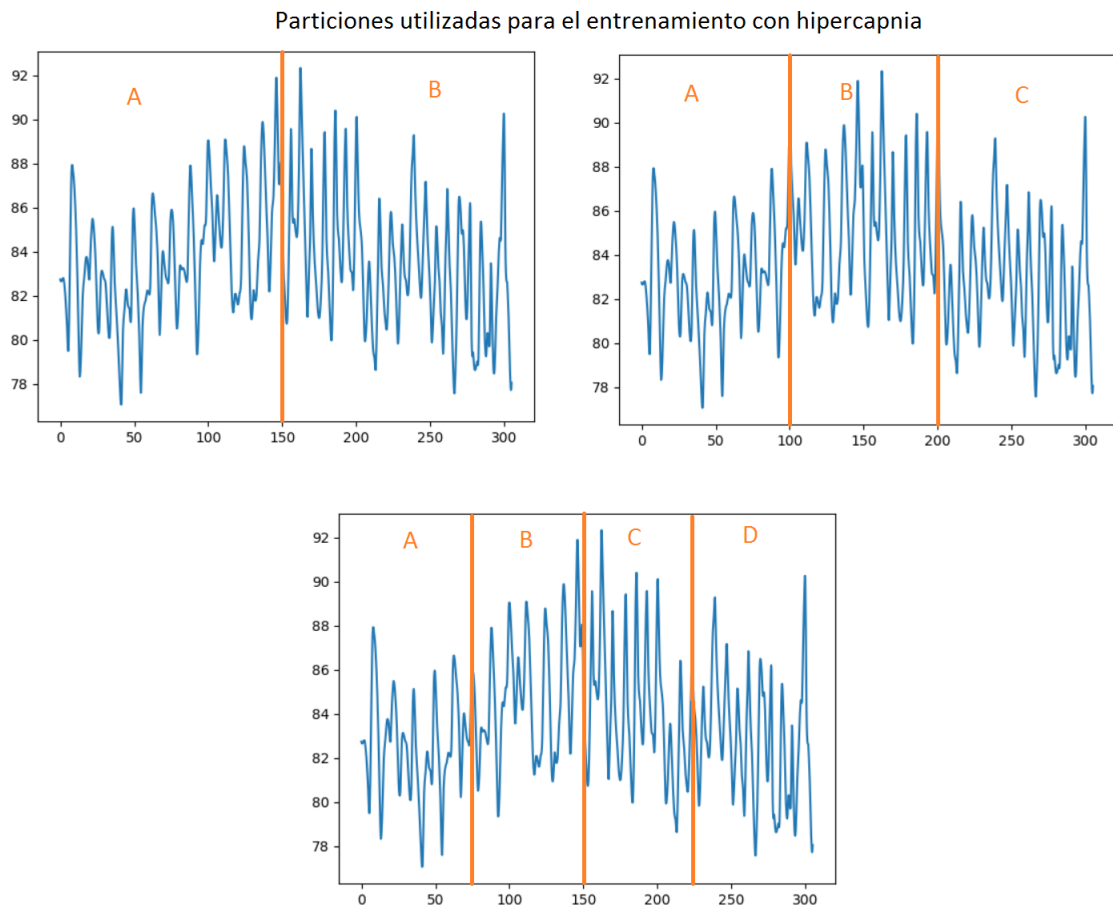


Figura 4.1: Conjuntos de entrada utilizados para el entrenamiento en hipercapnia (ABP).

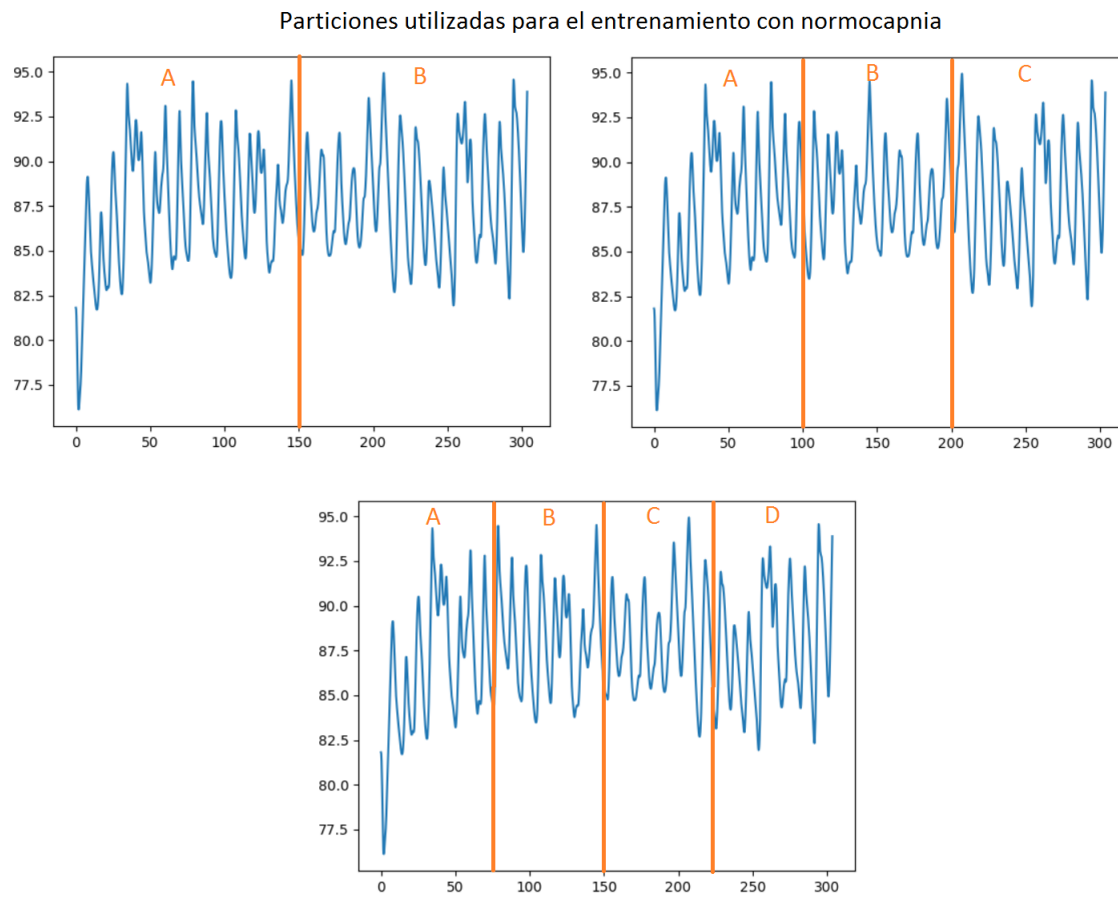


Figura 4.2: Conjuntos de entrada utilizados para el entrenamiento en normocapnia (ABP).

Particiones de salida utilizadas para el entrenamiento con hipercapnia




Figura 4.3: Conjuntos de salida utilizados para el entrenamiento en hipercapnia (CBFV).

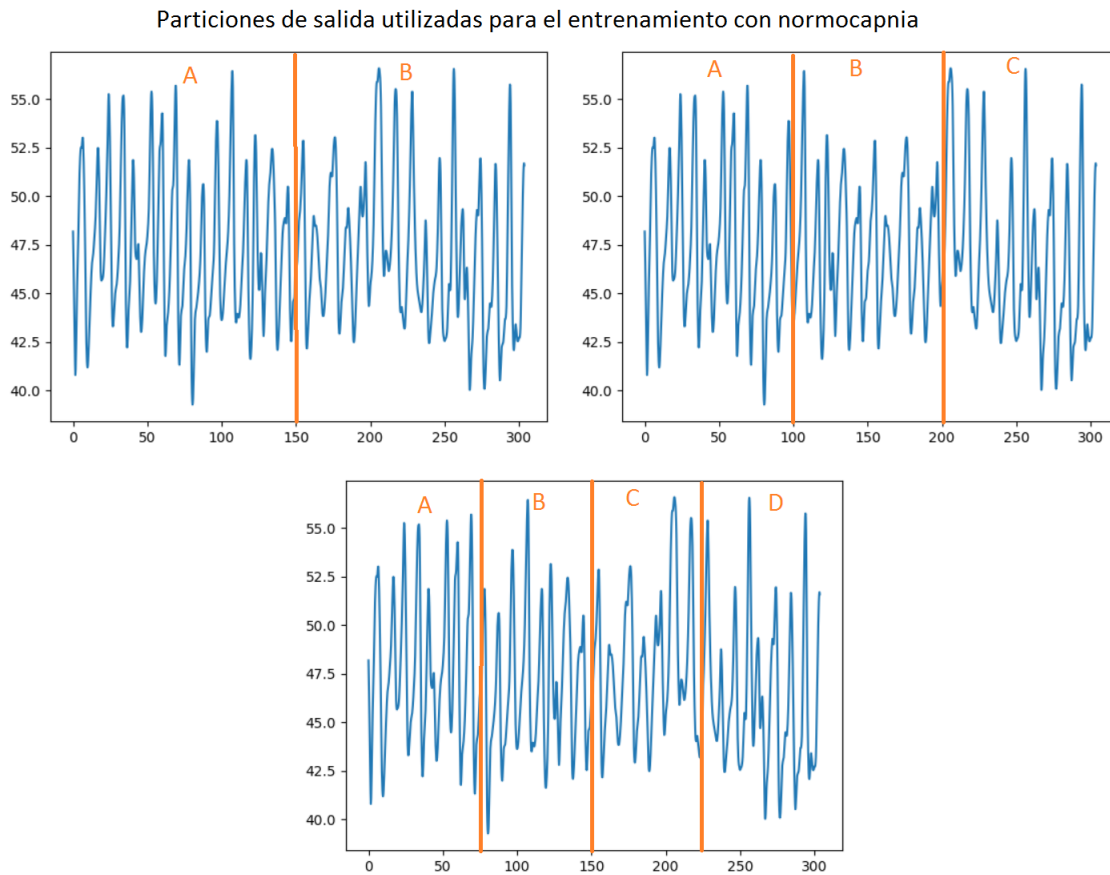


Figura 4.4: Conjuntos de salida utilizados para el entrenamiento en normocapnia (CBFV).

Hecho, es posible tener una visión rápida sobre qué señales son las utilizadas para el entrenamiento de la red neuronal con respecto a las diferentes posibles combinaciones de las particiones.

4.1 VALIDACIÓN CRUZADA K = 2

4.1.1 Entrenamiento Hipercapnia

Para esta red, como se menciona en el capítulo anterior, en el caso de hipercapnia se obtienen los mejores resultados entrenando con el conjunto A, tanto durante el entrenamiento

como durante la generalización. Esto se puede explicar debido a que durante los primeros dos minutos y 30 segundos, aproximadamente, la autorregulación cerebral está actuando, pero solo lidia con pequeños cambios de presión, ya que el cuerpo está estabilizado antes de la muestra.

Por lo tanto, se concluye que la autorregulación cerebral, si bien es estudiada a partir de grandes cambios en la ABP, sí es posible crear modelos en base a las pequeñas variaciones que aparecen durante un estado más estable del cuerpo y también que frente a pequeñas variaciones el mismo sujeto en estado de normocapnia e hipercapnia debería regular de un modo similar.

Sin embargo, cuando se estudian los resultados alcanzados por B, se observa que en esta sección es donde aproximadamente inicia la bajada de presión y por tanto la red comienza a aprender el patrón de recuperación de la CFBV un sujeto enfermo, lo que termina provocando que este modelo prediga pobremente la autorregulación cuando se estudia la generalización con los datos obtenidos durante el estado de normocapnia del mismo sujeto. Pero esta observación no es negativa, ya que desde el punto de vista de la red neuronal significa que la red aprendió un patrón sumamente bien, mas falla porque los datos son provenientes desde un estado diferente con respecto al que fue estudiado originalmente.

4.1.2 Entrenamiento Normocapnia

Para este caso se observa que durante el entrenamiento los mejores resultados son obtenidos con B, pero durante la generalización la situación se invierte y los mejores resultados son obtenidos con el grupo A. La explicación a esto nace desde la misma idea que lleva a las conclusiones obtenidas durante el entrenamiento con los datos en hipercapnia. Ya que, como se observó, la autorregulación es un fenómeno permanente, pero además se concluye que la señal estudiada para obtener los modelos está totalmente llena de ruido y es por eso que durante el entrenamiento con B, se obtienen resultados tan buenos, ya que es en ese punto en el que la autorregulación al hacer un esfuerzo más grande para mantener el CFBV constante es donde se manifiesta por sobre el ruido, permitiendo un entrenamiento más preciso.

Sin embargo, la situación es contraria durante el entrenamiento con B, ya que este modelo predice un regreso al estado homeostático de la CFBV mucho más rápido con respecto a un estado de hipercapnia llevando a errores más grandes. Mientras que A, es capaz de disminuir el error, debido a que aprende el proceso de autorregulación que se mantiene oculto entre el ruido durante los primeros segundos de la señal.

Por otro lado, estas ideas también se pueden cuestionar si se hace un análisis visual de las señales obtenidos en la figura 3.3 se observa la existencia de un patrón que tiende a ser imitado cuando se entrena con B, pero en la figura 3.2, no se logra apreciar un comportamiento cuando se entrena con la partición A. Por lo tanto, también se puede concluir que para las ideas expuestas anteriormente pueden ser comprobadas estrictamente utilizando otra medida de similaridad, tal como la correlación.

VALIDACIÓN CRUZADA $K = 3$

4.1.3 Hipercapnia

Los mejores resultados con los datos de hipercapnia y la utilización de tres grupos para la validación corresponde a los obtenidos con las particiones A y C, mientras que en cualquier otra combinación los resultados se empobrece.

Una de las posibles explicaciones para este fenómeno puede ser que la información de la autorregulación contenido en las señales A y C, es más significativa que la que está contenido en B. Dicho de otro modo, la señal A, es un lapso en el que la autorregulación está actuando de manera en un humano estabilizado y en C la autorregulación está actuando exclusivamente durante una bajada de presión y por lo tanto la red neuronal aprende desde estas dos situaciones. Sin embargo la señal B, contiene un comportamiento difuso, ya que está en el límite de los descritos anteriormente y por tanto la red aprendiendo un comportamiento incierto para la posterior predicción con el conjunto de generalización.

Sin embargo, si se observa la tabla 3.6, contenedora de los datos de los errores,

queda expresado que el MSER entrenando con A y B no es mucho mayor que el entrenado con A y C, de dónde es posible concluir que es esta sección la que contiene la información más importante, debido a que tiene la información del pasado sobre lo que estaba ocurriendo en la hemodinámica cerebral y más tarde esta puede ser complementada con la información contenido en las otras secciones.

4.1.4 Normocapnia

La situación para los resultados del modelo entrenado con datos en normocapnia se mantiene igual: El mejor modelo entrenado nace a partir de la utilización de las particiones final e inicial de la red.

También, se exhibe que visualmente hablando, se observa como el comportamiento real de la señal es imitado de mejor por el modelo entrenado con B y C. De lo que se puede concluir, que la señal de ABP en normocapnia con el modelo adecuado es capaz de predecir aceptablemente una señal de CFBV en hipercapnia siempre y cuando el modelo entrenado no haya sido obtenido con un lapso que contenga durante mucho tiempo el estado base de la señal en normocapnia. Lo que intuitivamente podría exponer que el instante de tiempo en que es obtenida la señal afecta a la calidad predictiva del modelo estudiado.

4.2 VALIDACIÓN CRUZADA K = 4

4.2.1 Hipercapnia

Durante la validación cruzada con cuatro partes nuevamente se observa que los mejores resultados durante el entrenamiento son obtenidos con la utilización de las señales en los momentos iniciales y en los momentos finales. Sin embargo, es necesario determinar qué información es la que mantiene la señal en la sección B, a qué se debe el aumento de la ABP

y cómo es que este trozo de la señal está afectando al desarrollo, entonces como se observa en hipercapnia con los trozos de la señal CBFV en la figura 4.3 es posible observar que en la sección B es posible observar una cierta regulación de la señal antes de volver a subir y llegar al estado final. Por lo tanto, se puede considerar la existencia de una transiente que tiene un punto sin variaciones antes de volver a aumentar y regularse definitivamente, lo que ocurre en los trozos C y D de la señal.

Sin embargo, cuando se generaliza el modelo para los datos obtenidos desde un sujeto en normocapnia los resultados empeoran, lo que puede llevar la conclusión de que es posible que el modelo necesita de la información contenido en el sector no considerado para poder extender su funcionamiento a otros contextos fisiológicos. Pero por otro lado, es posible definir la posible existencia de un sobre entrenamiento con el conjunto de datos y es por ello que todos los modelos al generalizar aumentan notoriamente el error, a diferencia de lo ocurrido en las validaciones anteriores.

4.2.2 Normocapnia

En este entrenamiento se produce una situación interesante, ya que los modelos entrenados con un conjunto que incluyera la sección D de las señales obtienen todos un MSER similar, lo que puede llevar a la idea de que esta sección de la señal tiene cierta información que las demás no tienen o que esta información permite determinar cómo se comportó la señal en momentos anteriores. Esto se explica, ya que al corresponder a los últimos momentos del muestreo luego de la maniobra quiere decir que el cuerpo ya estaba volviendo al estado de homeostasis original.

Es necesario destacar que existe aquí una idea subyacente que dice que el proceso general de la hemodinámica similar es un ciclo que podría predecirse independiente del tiempo, sin embargo llegar a esta conclusión no es del todo correcta, ya que por un lado, no solo se utiliza la señal D para realizar predicción sino que también otras dos, ya sea A, B o C, pero también está en contradicción con respecto a lo obtenido en el análisis anterior con la validación cruzada con k

=3, por que se determina que los modelos creados dependen del momento en que las muestras para entrenarlos son tomadas. Entonces se puede abrir el debate sobre si el fenómeno de la autorregulación cerebral es o no variante en el tiempo.

Mientras que por el lado de la generalización se obtiene que los resultados a nivel de error similares con cada modelo, por lo tanto se podría abrir un estudio que determine una forma de predecir modelos de comportamiento de la autorregulación cerebral en hipercapnia en base a la autorregulación de un sujeto en estado de normocapnia a partir del entrenamiento de un modelo con por lo menos cuatro particioneS.

CAPÍTULO 5. CONCLUSIONES

Durante el desarrollo de la experiencia se plantea el desarrollo de una red neuronal multicapa para la predicción de la CBFV en base a las ABP, esto quiere decir que en esta experiencia se busca resolver un problema de regresión.

Para esto se utiliza una validación cruzada de 2, 3 y 4 pliegues, para encontrar los mejores modelos y finalmente se realiza una generalización con datos obtenidos de sujetos en la condición contraria con respecto a la condición en la cuál es obtuvieron los datos, es decir, desde normocapnia a hipercapnia y viceversa.

En los resultados se observan una serie de características que dicen relación con el modo en que la señales obtenidas de un sujeto normocapnico son capaces de predecir de mejor modo una señal hipercapnica en la medida que se aumentan la cantidad de pliegues para el entrenamiento.

También se logra apreciar que el modelo utilizado depende del lapso de tiempo en que el sujeto está en reposo antes de la aplicación de la maniobra para que las predicciones tengan una mejor calidad.

Dentro de las mejores que se pueden agregar al desarrollo de esta experiencia se encuentran la utilización de gráficas de error tanto para el conjunto de test como el conjunto de entrenamiento, para aplicar técnicas de early stopping, sin la transparencia que implica la utilización del código empaquetado.

También, sería interesante poder realizar un feature extraction en base a la utilización de las transformadas mencionadas anteriormente, apunta a la utilización de una mayor cantidad de información con la cual alimentar a la red y así volver los resultados más valiosos desde el punto de vista de posibles parámetros que permita definir medidas clínicas para la evaluación de un paciente, por ejemplo.

Finalmente, en base a los objetivos, se logran mejorar los resultados ampliamente con respecto al laboratorio anterior y se logran aplicar ciertas técnicas de preprocesamiento, mas no todas las solicitadas, por tanto en este punto existe un nicho para potenciar los resultados obtenidos y durante la optimización de parámetros sería interesante obtener ciertas

BIBLIOGRAFÍA

Bajaj, S. (2017). So you built a machine learning model? Online; accessed 2017-12-10.

URL <http://sourabhbajaj.com/blog/2017/03/16/so-you-built-a-machine-learning-model/>

De Nápoli, P. (2017). Transformada de fourier. Online; accessed 2017-12-10.

URL http://mate.dm.uba.ar/~pdenapo/apuntes-mate4/transformada_fourier.pdf

Samir Kouro, M. R., R. (2017). Tutorial introductorio a la teoría de wavelet. Online; accessed 2017-12-10.

URL <http://www2.elo.utfsm.cl/~elo377/documentos/Wavelet.pdf>